

APEX 与原生执行环境的工程交付对照

四冲程柴油机生成任务的单案例研究

语言模型生成的工程演示必须同时满足结构、运动与交互约束，但可运行的页面和通过的自测并不保证这些约束成立。这里，我们在相同底层模型与原始任务下，对 APEX 1.0 和官方 Harness 原生执行环境各一次自然完成的四冲程柴油机交付进行比较。基于冻结量表、实际网格坐标、真实鼠标操作和浏览器呈现记录，APEX 与原生对照的原始评分分别为 83.8 和 72.8。原生对照出现最大 105 mm 的连杆连接分离，以及普通选中操作后的持续渲染冻结，触发硬上限后得分为 40.0。两组均未通过完整验收。APEX 的完成时间缩短 47.8%，输出 token 用量为对照的 4.63 倍。该案例呈现了较高交付评分、较短延迟与较高资源消耗并存的结果；单次、非盲且总预算不等的比较，尚不能证明普遍或因果性的能力提升。

工程演示将语言模型生成的代码转化为可观察对象：连杆需要与销轴连接，凸轮需要围绕固定轴线转动，交互操作需要在改变内部状态后真正更新画面。一个作品可以在外观上完整、在程序中包含正确公式，同时在这些关系上失效。因此，评估生成系统需要同时观察交付的功能、约束一致性和资源消耗。

多代理系统已被用于连接文献检索、假设生成与数据分析等研究环节¹。此类系统的表现涉及基础模型、工具、任务分解与反馈过程的共同作用。在另一些语言任务中，模型能力扩展也未能消除易被使用者忽略的错误²。这些发现提供了考察执行环境与结果可靠性的背景，但不能预先确定某一插件在工程任务中的效果。

本研究考察一个具体问题：在同一模型完成同一复杂三维任务时，APEX 配置交付的作品是否优于原生执行环境，差异付出了什么代价，又在哪些条件下失效。四冲程任务把进气、压缩、做功和排气组织为连续机械过程³，并同时要求完整零件、尺寸与间隙、流动显示、悬浮信息、剖视及稳定交互。它适合检验对象之间的关系，却不构成覆盖一般编程能力的任务集合。

冻结交付的单案例比较

两组均使用官方构建的 DeepSeek Harness，以及 deepseek-official 提供的 deepseek-flash，推理配置为 max。复用先前完成的 APEX 样本后，在全新工作目录和会话中提交同一原题，生成一次原生对照。两组各有一次父提示，均自然结束；评价方未追加提示、重投任务或修改成品。APEX 实际形成六个会话，原生对照为一个。原生子代理工具保留可用，实际未委派是该次运行的行为。

我们沿用包含 37 项、八类指标的 100 分量表，先计算有证据支持的原始分，再应用已证实严重故障对应的硬上限。完整验收状态另行判断。测量对象为冻结的实际交付，而非模型报告的自测结果；这里的“独立”指独立于成品自测，评价并非第三方盲评。两组仅各一次生成，因此所有差异均作为观察值报告。

评分差异包含部分质量差异与严重故障

APEX 的原始分为 83.8，原生对照为 72.8，相差 11.0 分（图 1a）。APEX 在八类评分中的观察值均较高，其中零件与装配为 23.4 对 21.7，四冲程运动为 20.0 对 16.8，尺寸与间隙为 3.1 对

1.6（各类满分分别为 24、24 和 6；图 1b）。尺寸类分数较低，表明视觉完成度与精密几何要求之间仍有明显距离。

原生对照触发持续交互/渲染失效的 C2 上限 40 分，以及关键机械连接失效的 C3 上限 55 分，最终分取原始分与适用上限中的最小值，为 40.0；APEX 未触发硬上限，保留原始 83.8 分。最终分相差 43.8 分，其中 32.8 分来自原生对照的封顶。仅移除 C2 时，对照为 55.0；移除全部硬上限时为 72.8。因而排序并不完全依赖 C2，但差值大小高度依赖严重故障如何计入评分。逐项依据及敏感性分析见补充表 1、2。

两份作品均未满足原题全部条件。原生对照的完整失败包括已证实的渲染与连接缺陷；APEX 仍有装配偏移、局部运动错误和信息不一致。83.8 分描述这份作品获得的部分信用，不代表通过工程验收，也不代表可用于制造或物理分析。

真实连接约束揭示表面运动下的错误

原生对照的活塞行程为 105 mm，连杆两孔中心距保持 410 mm，凸轮与曲轴的数值转角比为 1 : 2。但真实网格测量显示，在曲轴 90° 时，第 1 缸活塞销和连杆小头的纵向位置相同，横向却相差 105 mm（图 2a）。遍历 49 个曲轴角和四个气缸后，该完全分离仍是最大连接误差；相应孔轴与销轴还近乎垂直。长度守恒与转速比例正确，没有约束住实际装配。

原生对照的凸轮轴中心围绕错误原点作半径 240 mm 的轨道运动，相对初始位置最多平移 480 mm（图 2c）。凸轮与挺柱包围盒之间的最大分离下界为 418.34 mm，足以否定该状态下的接触。所有八个气门组的实际横向坐标集中在同一轴线，未与各缸弹簧对应。全局曲轴角 405° 时，第 3 缸被标为压缩，但进气门升程仍为 5.42 mm；第 4 缸被标为做功，排气门升程为 8.96 mm。部件存在、标签齐备和数值相位合理，均不能单独证明真实配气成立。

APEX 的连接误差较小，但仍未消失。其连杆大头与曲柄销存在 26 mm 轴向偏移，主轴承与轴颈偏移 23 mm；径向联动保持且支承仍部分重叠，因此原评分扣减装配分而未应用 C3。图 2b 同时给出两端三维中心距离，避免把 APEX 画成零误差参照。APEX 还出现约 9.13 mm 的推杆长度变化和最大约 3.01 mm 的凸轮/挺柱穿入。两组均没有证明原题要求的整体 0.1 mm 几何精度。




图 1 | 单次交付评分与资源消耗。a，原始分为空心圆，应用硬上限后的最终分为实心圆；两者相同处显示同心标记。连接线表示规则造成的分值变化，不是置信区间。原生对照触发 C2 = 40、C3 = 55，最终取 40.0；APEX 为 83.8。b，八类原始得分除以各类满分，便于查看类别内完成程度；各类权重不同，不能将百分比直接平均替代总分。R、S、K、F、I、V、D、P 的定义及满分见方法。c，从父提示提交至全会话树自然空闲的墙钟时间。d，APEX 相对原生对照的分类 token 用量比，虚线表示 1 倍；缓存写入均为零，未计算 0/0。每组为一次生成，无误差线。




图 2 | 原生对照的实际装配错误与渲染冻结。a，第 1 缸曲轴角 90° 的实测中心投影；连杆大、小头孔的连线保持 410 mm，小头却与活塞销横向分离 105 mm。虚线只连接应装配的两个测量中心，不代表实际零件。b，一次 720° 循环内，各固定角度四缸的最大三维连接误差；小头用实线，大头用虚线。APEX 大头 26 mm 为轴向偏移，原生对照小头为周期性径向脱离；接近零的两条曲线重叠。全部原记录另含第二循环，共 49 个角度。c，原生对照实际凸轮轴中心的 y-z 轨迹，圆点为测量位置；原点为错误旋转中心，轴心本应固定。d，新页面选中活塞前后的累计渲染帧数；浅灰带表示两次采样之间执行了选中操作，不表示精确动作时刻。末两次采样相隔约 1.2 s，计数均为 234，而内部相位继续变化。全部面板为同一成品内测量，不是独立生成重复。

普通交互暴露持续渲染失效

原生对照在新页面上的渲染计数先从 165 增至 225。使用作品自己的零件清单选中活塞后，计数到达 234 并在随后约 1.2 s 内保持不变，内部曲轴相位却继续变化（图 2d）。原因是原程序对 BoxHelper 访问了不存在的 box 属性，异常持续发生于最终渲染调用之前。真实画面冻结与内部状态推进由此分离。初次验收、全新页面复现，以及性能测量中旋转松手后的同类

异常，共同支持 C2 判定；后者发生在有效拖动测量窗口结束后。

这类失效与悬浮信息错误不同。原生对照在 12 类固定探测中完成 9 类正确命中，活塞和排气门出现已确认错卡，连杆因未获得有效探测位置而保持未验证。APEX 完成 11 类命中，但仍存在被剖切对象抢占、状态陈旧及喷油器显示未定义值等问题。完整零件清单和丰富说明并未保证所见对象、当前相位与显示信息一致。




图 3 | 固定测量窗口中的有效呈现。a-c，外观、剖视与流动、剖视与流动加持续旋转三种状态的逐秒有效呈现帧数；每状态预热 5 s 后连续记录 30 s。d，六个窗口各自的平均有效呈现帧率；点间连接仅对应相同显示状态。虚线为原题 60 FPS 阈值。视口 1440×900 、DPR 1、目标转速 2100 rpm，硬件及负荷差异见方法。原生对照第一个窗口后浏览器意外关闭，保留该窗口并在新浏览器只记录剩余状态；未择优。持续旋转窗口内呈现正常，但松手后发生原生对照的渲染故障。曲线的 30 个点不是 30 次独立生成，也未用于推断系统差异的显著性。

高帧率与较短延迟并不等于低代价的可靠交付

关闭外部演示后，我们在同一机器、Chrome 版本和 1440×900 视口下，对外观、剖视与流动、以及剖视与流动加持续旋转三个状态进行固定 30 s 测量。原生对照平均有效呈现帧率为 112.6、111.7 和 112.9 FPS，APEX 为 110.2、113.9 和 118.2 FPS（图 3）。各窗口均高于 60 FPS；原生对照外观窗口有一个超过 33.33 ms 的长帧。高帧率仅描述记录窗口中的呈现吞吐量，不能消除选中后的冻结，也不能说明机械关系正确。

从提交至全会话树自然空闲，APEX 用时 26 min 44.6 s，原生对照为 51 min 13.9 s，前者短 47.8%（图 1c）。与此同时，APEX 输出 token 为 1,229,906，对照为 265,713；非缓存输入为 451,959 对 160,939；缓存读取为 59,977,084 对 52,739,072，分别相当于对照的 4.63、2.81 和 1.14 倍（图 1d；补充表 3）。各类用量不合并为一个费用指标，两组缓存写入均为零。由于没有账单，不能从这些数字断言费用下降。

生成期间，APEX 自报 65 项自测通过，原生对照自报 51 项；APEX 的网页验证工具也出现通过记录。然而最终成品仍含上述错误。该结果说明，在这两个样本中，自测通过和实际约束成立之间存在缺口。工具调用数、自测数量和生成步骤数均未作为交付质量的替代终点。

讨论

本案例给出的结论是系统交付层面的：APEX 产生了评分较高、完成较快且 token 消耗较多的样本。它提供了继续评估 APEX 的理由，却没有识别改善来自何种机制。六个会话相对于一个

会话的执行，可能改变并行程度与探索量；工具、提示、团队组织和验证过程同时变化，也可能共同影响结果。当前比较没有把这些因素分离。

更直接的发现是，评价必须抵达成品的实际关系。连杆可以保持长度却脱离活塞销，凸轮可以满足 1:2 转角比例却绕错误位置公转，程序可以持续推进相位却停止提交画面。针对这些关系的检查，解释了为什么高视觉完成度、自测通过和高帧率仍可伴随完整验收失败。这一观察与已有工作对模型错误可识别性的关注相衔接²，但本研究不把语言问答领域的结论直接外推为工程生成的普遍规律。

解释本比较需要保留四项限制。首先，每组只有一个成品，角度、气缸、零件和逐秒帧率都是同一成品内的测量，不能充当独立生成重复。其次，APEX 先运行，评价者知道组别且参与过插件开发；任务选择与量表判断均可能影响结果。再次，两组未约束相同总计算预算，模型的随机性、服务状态和实际探索量均是竞争性解释。最后，原生对照缺少计划中的运行内服务身份见证；请求、有效配置与事后零提示复演支持其配置解释，但无法补造当时缺失的见证。目录分离也未证明所有读取通道均严格隔离。

下一阶段应把自然完成比较与等预算比较分开，预先冻结多个任务和严重失败规则，随机化运行顺序、增加重复，并对成品匿名评分。随后以单机制消融检验团队执行或验证工具的贡献。主要终点宜为完整任务通过率，并同时报告交付评分、严重故障率、延迟和分类用量。只有获得这些证据，才能判断当前观察到的差异是否稳定，以及额外资源消耗是否值得。

方法

实验对象与配置

实验于 2026 年 9 月 16 日完成。任务、量表与协议分别保存在 PROJECT_PROMPT.md、RUBRIC.md 和 PROTOCOL.md。两组使用全新工作目录与会话，工作目录的 AGENTS.md 为空；评价材料与生成目录分离。APEX 使用已有的 APEX 1.0 成品，原生对照为随后新生成的 standard 成品。不是随机分配实验，也不是前瞻性多题基准。未设置或锁定可复用的模型随机种子。

Harness 版本为 0.1.6-alpha.1，官方客户端对应源码提交为 0a15e36e7f82b6ed45af6fa9759f29b40dcd965d。启动前核验 official 构建身份、标题、提交与客户端文件内容摘要，沿用同一 live Home。底层提供方、模型、推理配置均为 deepseek-official / deepseek-flash / max。实际请求保留 adapter 原生每请求 maxTokens = 256000；这一限制不是任务总预算。评价方不另设总 token、步骤或墙钟上限，等待自然完成。

原生服务恢复与证据缺口

仅选择 standard 预设不能隔离已安装的 APEX 宿主服务替换。因此，对照通过一次性命令行配置恢复官方 subprocess、sandbox 与文件沙盒服务，关闭 APEX 相应临时运行时、适配与团队入口，不改变持久配置。原生工具，包括原生子代理能力，仍可使用。被动观察器只记录运行事件。

计划中的服务身份记录插件因中文路径编码错误未加载，驱动也并未将见证文件存在性作为提交前门槛。该次付费运行仍然完成并保留，未重新生成。实际请求含 26 个官方原生工具，未发现 APEX 工具或系统提示标识；有效配置亦符合恢复设计。事后在无模型提示条件下复演配置，通过服务原型、原型构造器、解包构造器和实例检查核对三个官方实现。该检查验证可复演的组合，不追溯替代原运行内见证。所有失败与恢复记录保留于补充材料。

成品冻结与测量边界

模型结束后保存全会话树日志、交付内容与文件摘要。官方导出器最初拒绝成品内部符号链接，在模型已自然结束后退出。只读恢复确认链接目标仍位于成品内，保留链接文本与目标摘要，并从既存请求、完成事件及空闲边界恢复记录。APEX 的原 71 个文件与原生对照的 26 个文件条目保持不变；APEX 额外出现的 Finder 元数据单列记录。评价探针仅在送入浏览器的模块响应末尾暴露原内部引用，未改写冻结文件或替换运动学。

机械、尺寸与信息检查

两组按同一份 49 个曲轴角列表采样，覆盖两个循环及边界附近位置，读取四缸真实网格的世界坐标。小头误差定义为连杆小头孔中心与活塞销中心的三维欧氏距离，大头误差相应使用连杆大头孔和曲柄销；各角度图示四缸最大值。图 2a 使用其中第 1 缸、90° 的 y-z 投影。凸轮轨迹来自实际轴中心；包围盒存在正距离能否定接触，包围盒重叠则不能证明接触。

圆截面离散误差按实际半径 r 与分段数 N 计算弦高 $r[1 - \cos(\pi/N)]$ ，核对世界缩放。原生对照有 24/77 个受检截面不超过 0.1 mm，APEX 为 20/37；截面计数依赖网格拆分，不能作为可直接比较的独立成功率。完整密闭燃烧室的几何压缩比保持未验证。流线支路最近距离使用 300 区间离散采样，为定位近似值，不作为连续曲线的严格最短距离。

悬停固定检查缸体、活塞、连杆、曲轴、进气门、排气门、喷油器、机油滤清器、水泵、进气管、缸盖螺栓和缸垫。由可见表面投影定位并发送真实鼠标操作，核对实际卡片与状态。没有有效探测位置和已确认错卡分别记录，不以易测对象替换失败项。对初次发现的渲染冻结追加新页面复现，保留初次结果。

呈现、时间与资源记录

性能环境为 Apple M5 Pro（20 核 GPU）、macOS 26.6.2、Chrome 152.0.7977.83、ANGLE Metal 与 120 Hz 显示设备。关闭外部演示后按原生对照、APEX 的顺序测量；视口 1440 × 900，DPR 1，保留默认部件和阴影，APEX 使用最高画质。两组目标转速为 2100 rpm。原生对照负荷为 75%，APEX 负荷由转速导出，并非相同物理负荷。

每个状态预热 5 s、记录 30 s。从 Chrome 原生 PipelineReporter 记录筛选已呈现且包含主动画的帧，并结合页面可见性、渲染计数与相位确认场景更新，使用呈现语义而非回调频率⁴。均值为有效呈现帧数除以 30 s，逐秒数与帧间隔仅描述该窗口。原生对照前两个窗口始转速约为 2034 和 2031 rpm，结束趋近 2100 rpm，因此不称为严格稳态测量。

原生对照第一个有效窗口结束后、第二个窗口开始前，浏览器意外关闭，原因未确定。保留已完成窗口，在新浏览器仅记录剩余两种状态一次，不择优重测；APEX 三状态在一个浏览器完成。后台恢复尝试中页面可见性始终报告 visible，因此后台恢复保持未验证。墙钟时间取提交至全会话树自然空闲，含轮询边界误差；原生对照时长由保存事件恢复。分类 token 由官方 token-meter 汇总全部会话树，不以主会话替代团队总用量。

评分、敏感性与统计单位

37 项指标分属可运行交付（8 分）、零件与装配（24 分）、四冲程运动（24 分）、流动与工况（10 分）、悬浮信息（12 分）、材质/剖视/视角（10 分）、尺寸与间隙（6 分）及性能/稳定性（6 分）。原始分为逐项加总；最终分为原始分与全部适用硬上限的最小值。C2、C3 分别设为 40、55。未验证可用分与已确认失败分开，不按潜在满分记入结果。无 C2、无全部硬上限两种敏感性计算均沿用同一组逐项得分。

APEX 的 83.8 为冻结的原评估结果，性能类仍保留各自首次验收评分。同条件补测若只更新 APEX 的 P2，可得到 84.8；这一补充重算不替代主结果，也不作为原评估已通过的追认。原生对照和 APEX 的未验证可用分分别为 1.0 与 0.7，并非统计置信区间。每组独立生成单位 $n = 1$ ；不计算显著性检验、置信区间、总体成功率或机制效应。

数据可用性

公开副本位于 GTC2080/dsh-APEX_Plugin 仓库的 papers/diesel-engine-2026-09-16/，包含原题、量表、脱敏评分、选定几何与性能测量，以及 data/source-data.json 和输入摘要。补充表 6 与 SANITIZATION.md 列出保留和删减范围。完整会话、原始 trace、截图、私人配置及冻结应用未公开；公开读者无法独立复验全部运行和成品判定。不声明数据 DOI。

代码可用性

reproduce/ 提供 plot-figures.py 与 build-paper.py，可从公开数据重建图表和论文，不再次调用模型。原始测量驱动未公开，绘图复现不等于重新执行原始测量。脱敏和公开排版未改变原始 APEX、Harness、两份冻结交付或评分。

参考文献

- Ghareeb, A. E. et al. A multi-agent system for automating scientific discovery. Nature 655, 497-505 (2026). <https://doi.org/10.1038/s41586-026-10652-y>
- Zhou, L. et al. Larger and more instructable language models become less reliable. Nature 634, 61-68 (2024). <https://doi.org/10.1038/s41586-024-07930-y>
- U.S. Department of Energy. Internal Combustion Engine Basics. <https://www.energy.gov/cmei/vehicles/articles/internal-combustion-engine-basics>（访问日期：2026-09-16）。
- The Chromium Authors. Debugging janks. Chromium documentation. [https://chromium.googlesource.com/chromium/src/+main/docs/speed/debug-janks.md](https://chromium.googlesource.com/chromium/src/+/main/docs/speed/debug-janks.md)（访问日期：2026-09-16）。